

Segmentación Inteligente de Servicios Clínicos mediante PCA y K-Means

Taller Final — Machine Learning

Juan Sebastián Laverde Chunza

Universidad El Bosque

Doctorado en Ciencia de Datos e Inteligencia Artificial

Machine Learning

2026

Contenido

1	Introducción	3
2	Datos y consulta analítica	3
3	Análisis exploratorio	4
4	Escalado	6
5	Análisis de Componentes Principales (PCA)	7
6	Interpretación de los loadings	8
7	Selección del número de clústeres	9
8	Segmentación mediante K-Means	10
9	Especialidad predominante por clúster	13
10	Importancia del escalado	13
11	Recomendaciones para la clínica	15
12	Respuestas consolidadas a las preguntas del taller	16
13	Conclusiones	17

1. Introducción

Este informe analiza una clínica ficticia que registra sus médicos, pacientes, citas y tratamientos en una base de datos relacional MySQL. La clínica quiere saber si sus citas forman **grupos naturales**, es decir, conjuntos de citas con duración, costo, satisfacción y tratamiento parecidos. Conocer esos grupos permite organizar mejor agendas, recursos y seguimiento.

Como no existe una etiqueta previa que indique a qué grupo pertenece cada cita, el problema es de **aprendizaje no supervisado**. Se aplican dos técnicas complementarias:

- **PCA (Análisis de Componentes Principales)** para resumir las seis variables numéricas en pocas componentes, conservando la mayor parte de la información.
- **K-Means** para agrupar las citas a partir de esas componentes.

Los resultados reportados provienen del notebook ejecutado del taller (`Taller_Clinica_Machine_Learning_LAVERDE.ipynb`); todas las cifras de este informe se tomaron de sus salidas.

2. Datos y consulta analítica

La información está distribuida en cuatro tablas relacionadas:

Tabla 1. Tablas de la base de datos de la clínica

Tabla	Contenido principal	Llave de relación
medicos	especialidad y datos del médico	id_medico
pacientes	edad y datos del paciente	id_paciente
citas	fecha, duración, costo y satisfacción	id_cita, id_paciente, id_medico
tratamientos	medicamento, dosis y días de tratamiento	id_cita

La tabla `citas` actúa como eje: cada cita se une con su paciente (`id_paciente`), con su médico (`id_medico`) y con el tratamiento asociado (`id_cita`). El resultado es una fila por cita con todas las variables necesarias. La consulta se ejecutó con un usuario de **solo lectura** (el notebook verificó con `SHOW GRANTS` que solo tiene permiso `SELECT`).

```
SELECT
  c.id_cita      AS id_cita,
  m.especialidad AS especialidad,
  p.edad        AS edad,
  c.duracion_min AS duracion_min,
  c.costos      AS costo_cita,
  t.dosis_mg    AS dosis_mg,
  t.dias_tratamiento AS dias_tratamiento,
  c.satisfaccion AS satisfaccion
```

```

FROM citas c
JOIN pacientes p      ON p.id_paciente = c.id_paciente
JOIN medicos m        ON m.id_medico   = c.id_medico
JOIN tratamientos t    ON t.id_cita    = c.id_cita
ORDER BY c.id_cita;

```

El conjunto analítico resultante tiene **200 registros y 8 columnas**. Su uso es el siguiente:

- **Seis variables numéricas** entran a PCA y K-Means: edad, duracion_min, costo_cita, satisfaccion, dosis_mg y dias_tratamiento.
- **especialidad** no entra al modelo; se conserva solo para interpretar los clústeres después de formarlos.
- **id_cita** es un identificador de trazabilidad y no se usa como variable de Machine Learning.

3. Análisis exploratorio

Calidad de los datos. Las 200 filas tienen las 8 columnas completas: **no hay valores faltantes** en ninguna variable y **no hay filas duplicadas**. Las variables numéricas son enteras (edad, duracion_min, dias_tratamiento, satisfaccion) o decimales (costo_cita, dosis_mg); especialidad es texto. La revisión de valores atípicos con el criterio del rango intercuartílico ($1,5 \times \text{RIC}$) **no detectó ningún outlier**, por lo que las 200 citas se conservan sin modificaciones.

Tabla 2. Estadísticas descriptivas de las seis variables numéricas ($n = 200$). Unidades: edad en años, duración en minutos, costo en pesos, dosis en mg, satisfacción en escala 1–5

Variable	Media	Desv. est.	Mín.	Q1	Mediana	Q3	Máx.
edad	39,04	11,65	19	29	38	48,25	61
duracion_min	38,75	12,26	20	30	37,5	50	60
costo_cita	227.250	71.121	110.000	177.500	210.000	300.000	350.000
dosis_mg	180,05	188,40	0,5	20	100	325	600
dias_tratamiento	37,67	30,99	1	15	30	60	120
satisfaccion	4,09	0,79	3	3	4	5	5

La Tabla 2 ya muestra el reto principal del análisis: **costo_cita** se mide en cientos de miles de pesos, mientras que **satisfaccion** solo toma valores entre 3 y 5. La satisfacción está concentrada en la parte alta de la escala: ninguna cita recibió calificación inferior a 3.




Figura 1. Distribución de las variables numéricas.

Las distribuciones no son normales. `dosis_mg` y `dias_tratamiento` son asimétricas a la derecha: la mayoría de las citas tiene dosis bajas y tratamientos cortos, con un grupo menor de dosis altas (500–600 mg) y tratamientos de alrededor de 90 días. `costo_cita` y `duracion_min` muestran varios picos, lo que sugiere que existen tipos de consulta distintos. `satisfaccion` es discreta, con tres valores (3, 4 y 5).




Figura 2. Diagramas de caja de las variables numéricas.

Los diagramas de caja confirman la ausencia de puntos fuera de los bigotes, coherente con el conteo de outliers igual a cero. También se aprecia la amplitud de `dosis_mg` y `dias_tratamiento` frente a variables más compactas como `edad`.




Figura 3. Matriz de correlación de las variables numéricas.

La relación más fuerte es entre `duracion_min` y `costo_cita` (0,99): en esta clínica, las consultas más largas son prácticamente siempre las más costosas. Ambas se relacionan de forma negativa con `satisfaccion` ($-0,82$ y $-0,81$): las consultas largas y costosas tienden a recibir calificaciones más bajas. `dias_tratamiento` tiene una relación moderada con duración y costo (0,35), y `edad` casi no se correlaciona con las demás variables. Esta redundancia entre variables es precisamente lo que PCA aprovecha para resumir la información.

4. Escalado

Antes de PCA y K-Means las seis variables se estandarizaron con `StandardScaler`. El motivo es práctico: ambos métodos trabajan con distancias y varianzas, y sin escalado una variable pesa según el tamaño de sus unidades, no según su importancia. Por ejemplo, una diferencia de 50.000 pesos en `costo_cita` es un cambio moderado, pero numéricamente sería miles de veces mayor que la diferencia entre la satisfacción mínima y máxima (2 puntos). Sin escalar, el costo decidiría casi todo el análisis.

Tras la transformación, el notebook verificó que las seis variables quedaron con **media 0,0000** y **desviación estándar 1,0000**. Así todas las variables participan en igualdad de condiciones.

5. Análisis de Componentes Principales (PCA)

Se ajustó PCA con todas las componentes posibles (seis) sobre los datos escalados para conocer cuánta varianza aporta cada una.

Tabla 3. Varianza explicada por cada componente principal (datos escalados)

Componente	Varianza explicada (%)	Varianza acumulada (%)
PC1	49,24	49,24
PC2	19,49	68,73
PC3	15,44	84,17
PC4	12,03	96,21
PC5	3,62	99,82
PC6	0,18	100,00




Figura 4. Varianza explicada por componente (barras) y varianza acumulada (línea), con la referencia del 80 %.

Tres componentes principales explican aproximadamente el 84,17 % de la varianza total. Con dos componentes solo se alcanza el 68,73 %, por debajo del criterio del 80 %; con tres se supera ese umbral por primera vez. Por eso el modelo conserva **tres componentes**, que reducen el problema de seis a tres dimensiones perdiendo menos del 16 % de la información.

Conviene distinguir dos usos: PC1 y PC2 se usan para **visualizar** las citas en un plano, pero K-Means se entrena con **las tres componentes** que exige el criterio del 80 %. Que la gráfica sea bidimensional no significa que dos componentes sean suficientes.




Figura 5. Proyección de las 200 citas sobre las dos primeras componentes principales.

La proyección ya sugiere estructura: aparece un grupo compacto a la izquierda, un grupo amplio a la derecha y un pequeño grupo aislado en la parte superior. Esta separación visual anticipa que existen segmentos de citas diferenciados.

6. Interpretación de los loadings

Los *loadings* indican cuánto participa cada variable original en cada componente. Para interpretarlos se atiende sobre todo a su **magnitud** (valor absoluto).

Tabla 4. Loadings de las componentes principales

Variable	PC1	PC2	PC3	PC4	PC5	PC6
edad	0,104	0,468	0,876	0,023	−0,050	−0,004
duracion_min	0,564	0,005	−0,040	−0,178	0,370	0,715
costo_cita	0,563	−0,002	−0,041	−0,173	0,404	−0,699
satisfaccion	− 0,520	0,185	0,006	0,142	0,821	0,020
dosis_mg	−0,113	0,719	−0,363	−0,566	−0,132	−0,008
dias_tratamiento	0,266	0,479	−0,312	0,773	−0,071	−0,002




Figura 6. Mapa de calor de los loadings de las componentes principales.

PC1 — intensidad de la consulta. Está dominada por `duracion_min` (0,564), `costo_cita` (0,563) y `satisfaccion` (0,520 en valor absoluto). Duración y costo se mueven en la misma dirección y la satisfacción en la contraria, lo mismo que mostraba la matriz de correlación. En términos prácticos, PC1 separa las consultas **cortas, económicas y bien calificadas** de las **largas, costosas y con menor satisfacción**.

PC2 — perfil del tratamiento. Está dominada por `dosis_mg` (0,719), seguida de `dias_tratamiento` (0,479) y `edad` (0,468). Duración y costo prácticamente no participan ($|\text{loading}| \approx 0,005$). PC2 describe, por tanto, el **tratamiento asociado a la cita** (dosis y duración) junto con la edad del paciente, y es independiente de lo que ocurre dentro de la consulta.

PC3, la tercera componente retenida, está dominada por `edad` (0,876); por eso permite diferenciar grupos que en el plano PC1–PC2 aparecen superpuestos.

7. Selección del número de clústeres

Se entrenó K-Means sobre las tres componentes retenidas para valores de k entre 2 y 8 (con `random_state = 42`) y se registró la inercia, que mide qué tan compactos son los grupos.

Tabla 5. Inercia de K-Means para cada valor de k y reducción respecto al valor anterior

k	2	3	4	5	6	7	8
Inercia	584,17	463,73	366,99	288,86	241,17	207,16	181,59
Reducción	—	120,44	96,74	78,13	47,69	34,01	25,57




Figura 7. Método del codo: inercia según el número de clústeres.

La inercia siempre baja al agregar clústeres, pero la ganancia se reduce. Hasta $k = 5$ cada clúster adicional reduce la inercia en 78 unidades o más; a partir de $k = 6$ la reducción cae a 48 y sigue disminuyendo. El punto de inflexión, identificado automáticamente con *KneeLocator*, es $k = 5$. El codo no es muy pronunciado, por lo que la elección se apoya también en que los cinco grupos resultan interpretables, como se muestra a continuación.

8. Segmentación mediante K-Means

El modelo final se entrenó con $k = 5$ sobre las tres componentes principales (`random_state = 42`, `n_init = 50`).




Figura 8. Clústeres de citas proyectados sobre PC1 y PC2.

Los clústeres 4 (izquierda), 1 (derecha) y 0 (arriba) están claramente separados en el plano. Los clústeres 2 y 3 se superponen en esta vista porque su diferencia principal está en PC3, es decir, en la edad; esto confirma el valor de conservar la tercera componente.

Tabla 6. Tamaño de cada clúster

Clúster	Número de citas	Porcentaje
0	10	5,0 %
1	62	31,0 %
2	35	17,5 %
3	52	26,0 %
4	41	20,5 %
Total	200	100,0 %




Figura 9. Número de citas por clúster.

El clúster 1 es el más grande (casi una de cada tres citas) y el clúster 0 el más pequeño (10 citas); sus conclusiones deben leerse con cautela por su tamaño.

Tabla 7. Perfil promedio de cada clúster en las variables originales (edad en años)

Clúster	Edad	Duración (min)	Costo (\$)	Satisf.	Dosis (mg)	Días trat.
0	41,10	35,00	205.000,00	5,00	600,00	90,00
1	40,31	53,63	312.741,94	3,15	146,05	50,48
2	53,06	37,57	221.428,57	4,26	155,71	37,14
3	29,58	35,48	210.384,62	4,21	107,52	36,73
4	36,66	22,32	129.756,10	5,00	241,82	7,15
<i>Global</i>	<i>39,04</i>	<i>38,75</i>	<i>227.250,00</i>	<i>4,09</i>	<i>180,05</i>	<i>37,67</i>

Clúster 0 — tratamientos de dosis máxima y mayor duración (10 citas). Todas sus citas tienen la dosis más alta del conjunto (600 mg) y satisfacción perfecta (5,0); sus tratamientos duran en promedio 90 días, el valor más alto entre los clústeres. Duración y costo de la consulta son cercanos o inferiores al promedio. Lo que lo distingue no es la consulta sino el tratamiento.

Clúster 1 — consultas largas y costosas con menor satisfacción (62 citas). Tiene la mayor duración (53,6 min), el mayor costo (\$312.742) y la menor satisfacción (3,15). Sus tratamientos son de duración superior al promedio (50,5 días). Es el grupo más numeroso y el de mayor exigencia de tiempo y recursos.

Clúster 2 — pacientes de mayor edad con perfil intermedio (35 citas). Su rasgo principal es la edad promedio más alta (53,1 años). Duración, costo, satisfacción, dosis y días de tratamiento están muy cerca del promedio general.

Clúster 3 — pacientes más jóvenes con dosis bajas (52 citas). Reúne a los pacientes más jóvenes (29,6 años) y la dosis promedio más baja (107,5 mg). El resto de su perfil es similar al del clúster 2; la edad es lo que los separa.

Clúster 4 — consultas breves y económicas con tratamientos cortos (41 citas). Tiene la menor duración (22,3 min), el menor costo (\$129.756) y los tratamientos más cortos (7,2 días), con satisfacción perfecta (5,0). Su dosis promedio (241,8 mg) supera la media global.

9. Especialidad predominante por clúster

La especialidad **no** se usó para formar los clústeres; se cruza con ellos después, para interpretarlos.

Tabla 8. Distribución de especialidades por clúster (número de citas; en negrita, la especialidad predominante)

Especialidad	Clúster 0	Clúster 1	Clúster 2	Clúster 3	Clúster 4	Total
Cardiología	0	28	3	5	0	36
Dermatología	0	1	8	22	2	33
Ginecología	10	0	9	8	4	31
Neurología	0	33	1	0	0	34
Ortopedia	0	0	14	17	0	31
Pediatría	0	0	0	0	35	35
Total	10	62	35	52	41	200

Tabla 9. Especialidad predominante en cada clúster

Clúster	Especialidad predominante	Participación en el clúster
0	Ginecología	10 de 10 (100,0 %)
1	Neurología	33 de 62 (53,2 %)
2	Ortopedia	14 de 35 (40,0 %)
3	Dermatología	22 de 52 (42,3 %)
4	Pediatría	35 de 41 (85,4 %)

Los clústeres 0 y 4 están casi completamente asociados a una especialidad (Ginecología y Pediatría). El clúster 1 combina **Neurología y Cardiología** (33 y 28 citas): ambas comparten consultas largas y costosas, aunque Cardiología no predomina en ningún clúster. Los clústeres 2 y 3 son mixtos: Ortopedia y Dermatología predominan, pero con menos de la mitad de las citas.

Esta asociación es **descriptiva**: indica que ciertas especialidades comparten patrones de duración, costo y tratamiento, no que la especialidad haya causado el clúster.

10. Importancia del escalado

Para responder qué ocurre sin escalar, el notebook repitió PCA y K-Means con las variables en sus unidades originales, manteniendo tres componentes y $k = 5$.

Tabla 10. Varianza explicada con y sin escalado (valores redondeados a dos decimales)

Componente	Con escalado (%)	Sin escalado (%)
PC1	49,24	100,00
PC2	19,49	0,00
PC3	15,44	0,00
PC4	12,03	0,00
PC5	3,62	0,00
PC6	0,18	0,00




Figura 10. Comparación de la varianza explicada por PCA con escalado y sin escalado.

Sin escalado, **PC1 concentra el 100,00 % de la varianza** (redondeado) y las demás componentes quedan prácticamente en cero. La explicación está en la Tabla 2: la desviación estándar de `costo_cita` (71.121) es cientos de veces mayor que la de cualquier otra variable (la siguiente es `dosis_mg`, con 188,40). Como la varianza es el cuadrado de la desviación, el costo aporta casi toda la varianza del conjunto y PC1 se convierte, en la práctica, en el costo de la cita. PCA deja de resumir las seis variables clínicas y solo refleja la unidad de medida más grande.

Tabla 11. Comparación de asignaciones de K-Means con y sin escalado (número de citas)

Con escalado \ Sin escalado	0	1	2	3	4
0	1	0	0	0	9
1	0	61	0	1	0
2	9	0	0	16	10
3	24	1	0	18	9
4	4	0	37	0	0

Los números de clúster son etiquetas arbitrarias, así que lo importante es si los grupos se conservan. Solo los dos grupos extremos en costo sobreviven: el clúster 1 (el más costoso) se mantiene casi intacto (61 de 62) y el clúster 4 (el más económico) conserva 37 de 41 citas. En cambio, los

clústeres 0, 2 y 3, que se distinguen por dosis, días de tratamiento y edad, se reparten entre varios grupos: por ejemplo, las 52 citas del clúster 3 terminan divididas en 24, 18, 9 y 1. Sin escalado, la segmentación ordena las citas casi solo por su costo.

Por eso la solución **con escalado** es el análisis principal: es la única en la que las seis variables contribuyen de manera equilibrada y en la que aparecen perfiles definidos por el tratamiento y la edad, no solo por el precio.

11. Recomendaciones para la clínica

Las recomendaciones son **operativas y administrativas**; ninguna implica decisiones de tratamiento, que el conjunto de datos no permite respaldar.

1. **Agenda diferenciada por duración (clústeres 1 y 4).** Las citas del clúster 1 duran en promedio 53,6 min y las del clúster 4, 22,3 min. Asignar franjas largas (cercanas a 60 min) al primer perfil y franjas cortas (20–25 min) al segundo reduce retrasos en cadena y tiempos muertos.
2. **Planeación de consultorios para el grupo más exigente (clúster 1).** Es el 31 % de las citas y el de mayor duración, sobre todo en Neurología y Cardiología. Reservar consultorios y personal de apoyo para estas especialidades en las franjas largas mejora el uso de la capacidad.
3. **Revisión de costos de las citas más caras (clúster 1).** Su costo promedio (\$312.742) supera en 38 % el promedio general, y el costo está casi completamente ligado a la duración (correlación 0,99). Conviene revisar si la tarifa refleja tiempo efectivo de atención y si hay oportunidades de optimizar la consulta.
4. **Seguimiento de la satisfacción (clúster 1).** Tiene la menor satisfacción (3,15, frente a 5,0 en los clústeres 0 y 4). Se recomienda una encuesta breve posterior a la cita para identificar causas, ya que el conjunto de datos no las registra (espera, comunicación, trámites u otras).
5. **Replicar las prácticas de los grupos mejor calificados (clústeres 0 y 4).** Ambos obtienen satisfacción de 5,0. Documentar cómo se organizan esas consultas (tiempos, información entregada al paciente) puede servir de referencia para el clúster 1.
6. **Seguimiento administrativo de tratamientos largos (clúster 0).** Sus tratamientos duran en promedio 90 días, con la dosis más alta (600 mg). Programar recordatorios y citas de control a lo largo del tratamiento facilita la continuidad. Dado que el grupo tiene solo 10 citas, debe validarse con más datos.
7. **Accesibilidad para pacientes de mayor edad (clúster 2).** Con 53,1 años de edad promedio y especialidades mixtas, este grupo puede beneficiarse de facilidades de acceso y horarios convenientes, organizados por perfil y no solo por especialidad.
8. **Actualizar la segmentación periódicamente.** Con 200 citas, los grupos son una primera aproximación; conviene repetir el análisis cuando crezca la base de datos para comprobar su estabilidad.

12. Respuestas consolidadas a las preguntas del taller

Pregunta 1. ¿Cuántas componentes principales explican al menos el 80 % de la varianza? ¿Por qué? Tres componentes, que explican el **84,17 %** de la varianza (PC1 49,24 %, PC2 19,49 % y PC3 15,44 %). Con dos componentes solo se llega al 68,73 %; la tercera es la primera que supera el umbral del 80 %. Esto es posible porque varias variables son redundantes, en especial duración y costo (correlación 0,99).

Pregunta 2. ¿Qué variables dominan PC1 y PC2? PC1 está dominada por `duracion_min` (0,564), `costo_cita` (0,563) y `satisfaccion` (−0,520): resume la intensidad de la consulta. PC2 está dominada por `dosis_mg` (0,719), seguida de `dias_tratamiento` (0,479) y `edad` (0,468): resume el perfil del tratamiento y la edad del paciente.

Pregunta 3. ¿Cuál es el número óptimo de clústeres según el método del codo? $k = 5$. Hasta cinco clústeres cada grupo adicional reduce la inercia en 78 unidades o más; desde seis, la reducción cae a 48 y sigue bajando. `KneeLocator` identificó el codo en $k = 5$.

Pregunta 4. Perfil promedio de cada clúster.

Tabla 12. Resumen del perfil promedio por clúster

Clúster	Edad	Duración (min)	Costo (\$)	Satisf.	Dosis (mg)	Días trat.
0	41,10	35,00	205.000,00	5,00	600,00	90,00
1	40,31	53,63	312.741,94	3,15	146,05	50,48
2	53,06	37,57	221.428,57	4,26	155,71	37,14
3	29,58	35,48	210.384,62	4,21	107,52	36,73
4	36,66	22,32	129.756,10	5,00	241,82	7,15

En síntesis: el clúster 0 reúne tratamientos de dosis máxima y mayor duración; el 1, consultas largas, costosas y con menor satisfacción; el 2, pacientes de mayor edad con perfil intermedio; el 3, pacientes más jóvenes con dosis bajas; y el 4, consultas breves y económicas con tratamientos cortos.

Pregunta 5. ¿Qué especialidad predomina en cada clúster? Clúster 0: Ginecología (100 %); clúster 1: Neurología (53,2 %, seguida de Cardiología con 45,2 %); clúster 2: Ortopedia (40,0 %); clúster 3: Dermatología (42,3 %); clúster 4: Pediatría (85,4 %).

Pregunta 6. ¿Cómo cambian los resultados si no se escalan las variables? Cambian de forma sustancial. Sin escalado, PC1 explica el 100,00 % de la varianza porque `costo_cita` tiene una desviación estándar (71.121) cientos de veces mayor que las demás variables. K-Means solo conserva los grupos extremos en costo (clúster 1: 61 de 62 citas; clúster 4: 37 de 41) y dispersa los clústeres 0, 2 y 3, que dependen de dosis, días de tratamiento y edad (Tabla 10, Tabla 11 y Figura 10).

Pregunta 7. ¿Qué acciones concretas propondrías para la clínica? Agenda con franjas largas para el clúster 1 (53,6 min) y cortas para el clúster 4 (22,3 min); reserva de consultorios para Neurología y Cardiología; revisión de tarifas del clúster 1 (\$312.742); encuesta de satisfacción para el clúster 1 (3,15); documentar las prácticas de los clústeres 0 y 4 (satisfacción 5,0); recordatorios

y controles para los tratamientos largos del clúster 0 (90 días en promedio); facilidades de acceso para el clúster 2 (53,1 años); y repetir la segmentación al crecer la base de datos.

Pregunta 8. ¿Qué riesgos éticos implicaría usar estos clústeres para decisiones clínicas?

El uso de estos clústeres para decisiones clínicas implica riesgos relacionados con sesgos en los datos, privacidad de la información y posibles interpretaciones incorrectas de los grupos. Los clústeres representan patrones estadísticos y no diagnósticos médicos, por lo que deben utilizarse como apoyo al análisis y no como sustituto del criterio profesional.

13. Conclusiones

El taller integró una base de datos relacional de cuatro tablas mediante una consulta JOIN, que produjo un conjunto limpio de 200 citas sin faltantes, duplicados ni valores atípicos. Tras estandarizar las variables, PCA redujo seis variables a **tres componentes que conservan el 84,17% de la varianza**; la primera resume la intensidad de la consulta (duración, costo y satisfacción) y la segunda, el tratamiento y la edad.

K-Means, con $k = 5$ según el método del codo, encontró cinco perfiles de citas diferenciados e interpretables, asociados de manera descriptiva a especialidades concretas. La comparación sin escalado mostró que este paso es indispensable: sin él, el costo domina todo el análisis.

Los resultados son útiles para el análisis exploratorio y la gestión operativa (agendas, consultorios, costos y seguimiento de la satisfacción), pero no tienen validez clínica: los clústeres describen patrones de atención, no condiciones de los pacientes, y deben validarse con más datos antes de apoyar decisiones.