

Taller práctico: Regresión lineal para predicción de precios de viviendas

Doctorado en Ciencia de Datos e Inteligencia Artificial

Juan Sebastián Laverde Chunza

10 de septiembre de 2026

Contenido

Objetivo	3
Actividades a desarrollar	3
1 Carga y exploración de datos	3
1.1 Carga del conjunto de datos	3
1.2 Realice una exploración inicial:	4
1.2.1 Verifique la cantidad de registros y columnas.	4
1.2.2 Identifique la presencia de valores nulos.	4
1.2.3 Calcule estadísticas descriptivas básicas (media, mediana, desviación estándar, etc.) para ambas variables.	4
Gráfica 1 — Distribución del tamaño	5
Gráfica 2 — Distribución del precio	6
Gráfica 3 — Boxplot del tamaño - precio	6
2 Tratamiento de datos faltantes (imputación)	7
2.1 Identifique qué porcentaje de datos faltantes tiene cada columna.	7
2.2 Seleccione una estrategia de imputación adecuada (ej. media, mediana, eliminación de filas, etc.) y justifique su elección.	7
3 Construcción del modelo de regresión lineal	10
3.1 Preparar el dataset para modelamiento	10
3.2 Divida el dataset en dos conjuntos:	10
3.3 Entrene un modelo de regresión lineal simple utilizando la librería scikit-learn o statsmodels.	11
3.3.1 Parámetros obtenidos	11
4 Evaluación del modelo	12
4.1 Calcule las métricas de rendimiento: R^2 (coeficiente de determinación), RMSE (raíz del error cuadrático medio) y Error porcentual absoluto medio (MAPE)	12

4.2	Interprete los resultados:	12
4.2.1	¿Qué porcentaje de la variabilidad del precio explica el modelo?	13
4.2.2	¿Qué tan precisas son las predicciones?	13
5	Predicción interactiva	14
6	Visualización de resultados	15
6.1	Dispersión y línea de regresión	15
6.2	Gráfico de residuos	15
	Conclusiones	17

Objetivo

Construir un modelo de regresión lineal simple que permita estimar el precio de una vivienda a partir de su tamaño en metros cuadrados, utilizando un conjunto de datos de **100.000 registros** con valores faltantes.

El desarrollo completo del código, incluidas las pruebas detalladas de los métodos de imputación, se encuentra en el notebook de Google Colab que acompaña este informe. En este documento se presentan la metodología, los resultados principales y su interpretación.

Actividades a desarrollar

1. Carga y exploración de datos

1.1. Carga del conjunto de datos

El conjunto de datos se carga directamente desde la URL proporcionada utilizando la librería `pandas`.

```
# =====  
# 1. CARGA DEL CONJUNTO DE DATOS  
# =====  
  
import pandas as pd  
  
# Cargar directamente el archivo CSV desde Google Cloud Storage  
dataset = pd.read_csv(  
    'https://storage.googleapis.com/bucket_doctorado_ueb_2026_2/datos_viviendas_faltantes.csv'  
)
```

El conjunto de datos contiene **100.000 registros** y dos variables numéricas continuas:

Variable	Descripción	Unidad
<code>tamano</code>	Tamaño de la vivienda	m^2
<code>precio</code>	Precio de la vivienda	COP

A continuación, se presentan las primeras diez observaciones del conjunto de datos.

	tamano	precio
0	NaN	532530.0
1	143.8	351732.0
2	179.1	526522.0
3	218.5	565288.0
4	139.5	382380.0

	tamano	precio
5	NaN	401130.0
6	NaN	596775.0
7	184.5	427445.0
8	128.9	441341.0
9	174.4	542720.0

1.2. Realice una exploración inicial:

1.2.1. Verifique la cantidad de registros y columnas.

DIMENSIONES DEL CONJUNTO DE DATOS

=====

Número de registros : 100,000

Número de columnas : 2

NOMBRES DE LAS COLUMNAS

=====

['tamano', 'precio']

El conjunto de datos contiene 100.000 registros y 2 variables: tamano y precio.

1.2.2. Identifique la presencia de valores nulos.

VALORES NULOS POR VARIABLE

=====

	Variable	Valores nulos	Porcentaje (%)
0	tamano	10000	10.0
1	precio	5000	5.0

En el conjunto de datos, la variable **tamano** presenta un 10 % de valores faltantes, equivalente a 10.000 registros, mientras que la variable **precio** presenta un 5 %, correspondiente a 5.000 registros. La siguiente gráfica permite visualizar y comparar la proporción de valores faltantes en ambas variables.

1.2.3. Calcule estadísticas descriptivas básicas (media, mediana, desviación estándar, etc.) para ambas variables.

Las estadísticas descriptivas iniciales se presentan en la Tabla 1.




Figura 1: Porcentaje de valores nulos por variable.

Tabla 1: Estadísticas descriptivas de las variables originales.

Variable	N	Media	Mediana	Desv. Est.	Mín.	Q1	Q3	Máy.
tamano	90000	150.07	150.1	44.91	30.0	119.60	180.40	351.6
precio	95000	425238.13	425243.5	123138.41	30000.0	342106.75	508401.25	1002767.0

La similitud entre media y mediana sugiere que las distribuciones no presentan una asimetría extrema. Además, desde la exploración inicial se observa una relación positiva fuerte entre el tamaño y el precio de las viviendas.

Gráfica 1 — Distribución del tamaño

Esta gráfica nos permite observar si los tamaños están concentrados en determinados intervalos y comparar visualmente media y mediana.




Figura 2: Distribución del tamaño de las viviendas, con media y mediana.

Gráfica 2 — Distribución del precio

Para el precio conviene evitar que Python muestre números como $2.5e8$ (Notación científica). Podemos darle formato de pesos.

Gráfica 3 — Boxplot del tamaño - precio

Ahora podemos comprobar visualmente la existencia de posibles valores extremos.

Con este gráfico podemos observar:

- mediana;
- rango intercuartílico;
- dispersión;
- posibles valores atípicos.




Figura 3: Distribución del precio de las viviendas, con media y mediana.

2. Tratamiento de datos faltantes (imputación)

2.1. Identifique qué porcentaje de datos faltantes tiene cada columna.

RESUMEN DE VALORES FALTANTES

=====

Tabla 2: Resumen de valores faltantes

	Variable	Valores faltantes	Valores observados	Porcentaje faltante (%)
0	tamano	10000	90000	10.0
1	precio	5000	95000	5.0

El análisis conjunto mostró que el **85,5 %** de los registros estaba completamente observado; el **9,5 %** tenía únicamente **tamano** faltante, el **4,5 %** únicamente **precio** faltante y el **0,5 %** presentaba ambas variables faltantes.

2.2. Seleccione una estrategia de imputación adecuada (ej. media, mediana, eliminación de filas, etc.) y justifique su elección.

Se compararon métodos simples y multivariados de imputación. Para seleccionar la estrategia se utilizó el **NRMSE promedio**, donde un valor menor indica una mejor capacidad de reconstrucción de datos conocidos que fueron ocultados temporalmente durante la validación.




Figura 4: Diagramas de caja del tamaño y del precio de las viviendas.

Tabla 3: Comparación de los métodos de imputación.

Posición	Método	NRMSE promedio
1	IterativeImputer + BayesianRidge	0,3926
2	KNN ($k = 5$)	0,4751
3	Mediana	0,9997
4	Media	0,9997




Figura 5: NRMSE promedio de los métodos de imputación evaluados.

Se seleccionó **IterativeImputer con BayesianRidge** porque obtuvo el menor error de reconstrucción y, a diferencia de la media o la mediana, aprovecha la relación existente entre **tamano** y **precio**.

Después de la imputación, ambas variables quedaron con **0 valores faltantes**. Las estadísticas antes y después permanecieron muy similares y la correlación entre **tamano** y **precio** pasó de **0,9143 a 0,9252**.

Este cambio es pequeño y muestra que la fuerte relación lineal positiva se conservó sin una alteración sustancial de la estructura de los datos.

VERIFICACIÓN POSTERIOR A LA IMPUTACIÓN

=====

	Variable	Valores faltantes	Porcentaje faltante (%)
0	tamano	0	0.0
1	precio	0	0.0

3. Construcción del modelo de regresión lineal

3.1. Preparar el dataset para modelamiento

VARIABLES DEL MODELO

```
=====
Variable predictora (X): ['tamano']
Variable objetivo (y): precio
```

Dimensiones de X: (100000, 1)

Dimensiones de y: (100000,)

Aquí definimos las variables predictora y objetivo a partir del dataset limpio completo:

3.2. Divida el dataset en dos conjuntos:

Se utilizó el **dataset completo después de la imputación**. La variable predictora fue **tamano** y la variable objetivo fue **precio**.

El conjunto de datos se dividió de la siguiente manera:

Tabla 4: División del conjunto de datos.

Conjunto	Registros	Porcentaje
Entrenamiento	80.000	80 %
Prueba	20.000	20 %

```
# =====
# 3.2 DIVISIÓN EN ENTRENAMIENTO Y PRUEBA
# =====

from sklearn.model_selection import train_test_split

X_train, X_test, y_train, y_test = train_test_split(
    X,
    y,
    test_size=0.20,
    random_state=0
)
```

```

print("DIVISIÓN DEL CONJUNTO DE DATOS")
print("=" * 70)

print(f"Entrenamiento (80%): {len(X_train):,} registros")
print(f"Prueba (20%): {len(X_test):,} registros")

```

El dataset imputado se dividió en **80.000 registros para entrenamiento (80 %)** y **20.000 para prueba (20 %)**. Se utilizó `random_state=0` para garantizar que la partición sea reproducible.

3.3. Entrene un modelo de regresión lineal simple utilizando la librería scikit-learn o statsmodels.

```

# =====
# 3.3 ENTRENAMIENTO DEL MODELO DE REGRESIÓN LINEAL
# =====

from sklearn.linear_model import LinearRegression

# Crear el modelo
modelo = LinearRegression()

# Entrenar el modelo
modelo.fit(X_train, y_train)

print("MODELO ENTRENADO CORRECTAMENTE")
print("=" * 70)

```

3.3.1. Parámetros obtenidos

```

# =====
# 3.4 PARÁMETROS DEL MODELO
# =====

intercepto = modelo.intercept_
coeficiente = modelo.coef_[0]

print("PARÁMETROS ESTIMADOS DEL MODELO")
print("=" * 70)

print(f"Intercepto ( ): ${intercepto:,.2f}")
print(f"Coeficiente ( ): ${coeficiente:,.2f} por m2")

print("\nECUACIÓN DEL MODELO")
print("=" * 70)

```

```
print(
    f"Precio estimado = "
    f"{intercepto:,.2f} + "
    f"{coeficiente:,.2f} × tamaño"
)
```

Interpretación de los parámetros

El modelo estimado fue:

$$\widehat{Precio} = 43.002,89 + 2.547,77 \times tamaño$$

El coeficiente indica que, en promedio, por cada $1 m^2$ adicional, el precio estimado aumenta aproximadamente en **\$2.547,77 COP**.

El **intercepto de \$43.002,89 COP** representa el precio estimado cuando el tamaño es $0 m^2$; sin embargo, su interpretación práctica es limitada, ya que una vivienda de $0 m^2$ no tiene sentido real.

4. Evaluación del modelo

4.1. Calcule las métricas de rendimiento: R^2 (coeficiente de determinación), RMSE (raíz del error cuadrático medio) y Error porcentual absoluto medio (MAPE)

Una vez entrenado el modelo de regresión lineal, se evalúa su capacidad predictiva utilizando exclusivamente el conjunto de prueba.

Se calculan las siguientes métricas:

- **R^2 (coeficiente de determinación):** indica qué proporción de la variabilidad del precio es explicada por el tamaño de la vivienda.
- **RMSE (raíz del error cuadrático medio):** mide la magnitud promedio del error de predicción, penalizando con mayor intensidad los errores grandes.
- **MAPE (error porcentual absoluto medio):** expresa el error promedio de las predicciones en términos porcentuales.

Para las métricas RMSE y MAPE, valores menores indican un mejor desempeño. En R^2 , valores más cercanos a 1 indican una mayor capacidad explicativa del modelo.

4.2. Interprete los resultados:

PREDICCIONES REALIZADAS CORRECTAMENTE

=====

Número de predicciones: 20,000

El desempeño se evaluó sobre los **20.000 registros** del conjunto de prueba.

RESUMEN DEL RENDIMIENTO DEL MODELO

=====

	Métrica	Resultado
0	R ²	0.8539
1	RMSE	\$46,668.86 COP
2	MAPE	9.65 %

El modelo explica aproximadamente el **85,39 % de la variabilidad del precio** a partir del tamaño de la vivienda.

El **RMSE fue de \$46.668,86 COP** y el **MAPE de 9,65 %**, lo que indica que las predicciones presentan, en promedio, un error porcentual cercano al 9,65 % respecto al precio real.

En conjunto, los resultados muestran un buen desempeño predictivo para un modelo lineal simple con una única variable explicativa.

4.2.1. ¿Qué porcentaje de la variabilidad del precio explica el modelo?

El coeficiente de determinación obtenido fue:

$$R^2 = 0.8539$$

Esto significa que el modelo de regresión lineal explica aproximadamente el 85.39 % de la variabilidad observada en el precio de las viviendas a partir de su tamaño en metros cuadrados.

En otras palabras, el tamaño de la vivienda presenta una capacidad explicativa importante sobre el precio dentro de este conjunto de datos. El 14.61 % restante de la variabilidad no es explicado por este modelo lineal simple y puede estar asociado con otros factores que no están incluidos en el análisis, como la ubicación, el estrato, el número de habitaciones, la antigüedad de la vivienda, entre otras características.

4.2.2. ¿Qué tan precisas son las predicciones?

El modelo obtuvo:

$$\text{RMSE} = 46,668.86 \text{ COP}$$

y

$$\text{MAPE} = 9.65 \%$$

El RMSE de \$46,668.86 COP indica que los errores de predicción tienen una magnitud de aproximadamente \$46,669 COP, teniendo en cuenta que esta métrica penaliza con mayor intensidad los errores grandes.

Por otra parte, el MAPE de 9.65 % indica que, en promedio, las predicciones realizadas por el modelo se alejan aproximadamente un 9.65 % del precio real de las viviendas.

Por lo tanto, el modelo presenta una buena capacidad predictiva para este conjunto de datos, ya que explica cerca del 85.39 % de la variabilidad del precio y mantiene un error porcentual promedio inferior al 10 %. Sin embargo, sus predicciones no son exactas y todavía existe variabilidad asociada con factores diferentes al tamaño de la vivienda.

5. Predicción interactiva

Una vez entrenado y evaluado el modelo de regresión lineal, se implementa una herramienta interactiva que permite ingresar el tamaño de una vivienda en metros cuadrados y obtener automáticamente su precio estimado.

La predicción se realiza utilizando el modelo entrenado previamente, cuya variable predictora es **tamano** y cuya variable objetivo es **precio**.

```
# =====
# 5.1 FUNCIÓN PARA REALIZAR PREDICCIONES
# =====

import pandas as pd

def predecir_precio(tamano_vivienda):

    # Crear DataFrame con el mismo nombre de variable
    # utilizado durante el entrenamiento
    nueva_vivienda = pd.DataFrame({
        'tamano': [tamano_vivienda]
    })

    # Realizar la predicción
    precio_estimado = modelo.predict(nueva_vivienda)[0]

    return precio_estimado

# =====
# 5.2 PRUEBA DEL MODELO
# =====

tamano_prueba = 150

precio_estimado = predecir_precio(tamano_prueba)

print("PREDICCIÓN DEL PRECIO DE LA VIVIENDA")
print("=" * 70)
```

```
print(
    f"Vivienda de {tamano_prueba:.0f} m2 "
    f"→ Precio estimado: ${precio_estimado:,.2f} COP"
)
```

La implementación interactiva se encuentra en el notebook de Colab. Para efectos del informe se presenta una prueba con una vivienda de 150 m^2 :

El precio estimado para una vivienda de 150 m^2 es de \$425,168.27 COP

Vivienda de $150\text{ m}^2 \rightarrow$ Precio estimado: \$425.168,27 COP

La predicción corresponde al valor esperado por el modelo según la relación aprendida entre tamaño y precio. No representa necesariamente el precio exacto de una observación individual, ya que existe variabilidad alrededor de la tendencia lineal.

6. Visualización de resultados

Finalmente, se visualiza el comportamiento del modelo de regresión lineal mediante:

- Un **gráfico de dispersión** entre **tamano** y **precio**, acompañado de la línea de regresión estimada.
- Un **gráfico de residuos**, utilizado para analizar el comportamiento de los errores de predicción.

6.1. Dispersión y línea de regresión

El gráfico Figura 6 evidencia una relación lineal positiva entre el tamaño y el precio de las viviendas. La línea de regresión representa la tendencia estimada por el modelo: a medida que aumenta el tamaño de la vivienda, también aumenta su precio esperado.

6.2. Gráfico de residuos

Las predicciones del conjunto de prueba, que ya calculamos: `y_pred = modelo.predict(X_test)`

El residuo se calcula como:

$$\text{Residuo} = \text{Precio}_{\text{real}} - \text{Precio}_{\text{estimado}}$$

Los residuos se distribuyen principalmente alrededor de cero, sin evidenciar una curvatura marcada, lo que respalda el uso de un modelo lineal. Sin embargo, se observan algunos errores extremos y cierta estructura en la dispersión, probablemente asociada a los valores imputados. En general, el comportamiento de los residuos es consistente con el buen desempeño predictivo obtenido por el modelo.




Figura 6: Relación entre tamaño y precio con la línea de regresión estimada.




Figura 7: Distribución de los residuos del modelo de regresión.

Conclusiones

El tratamiento de los datos faltantes mediante **IterativeImputer + BayesianRidge** permitió obtener un conjunto completo conservando adecuadamente la estructura de los datos. La estrategia fue seleccionada mediante una comparación empírica y presentó el menor NRMSE promedio entre los métodos evaluados.

Posteriormente, el modelo de regresión lineal obtuvo un R^2 de **0,8539** y un MAPE de **9,65 %**, evidenciando que el tamaño explica una proporción importante de la variabilidad del precio y que el modelo ofrece una capacidad predictiva adecuada para el objetivo planteado.

El notebook de Colab conserva el **desarrollo técnico completo y reproducible**, mientras que este informe resume los elementos metodológicos, resultados e interpretaciones necesarios para la entrega académica.