

Taller práctico: Regresión lineal para predicción de precios de viviendas

Doctorado en Ciencia de Datos e Inteligencia Artificial

Juan Sebastián Laverde Chunza

10 de septiembre de 2026

Contenido

Objetivo	1
1. Carga y exploración de datos	2
2. Tratamiento de datos faltantes	2
Selección del método de imputación	2
3. Construcción del modelo de regresión lineal	3
4. Evaluación del modelo	3
5. Predicción	4
6. Visualización de resultados	5
Datos y línea de regresión	5
Análisis de residuos	6
Conclusiones	6

Objetivo

Construir un modelo de **regresión lineal simple** que permita estimar el precio de una vivienda a partir de su tamaño en metros cuadrados, utilizando un conjunto de datos de 100.000 registros con valores faltantes.

El desarrollo completo del código, incluidas las pruebas detalladas de los métodos de imputación, se encuentra en el **notebook de Google Colab** que acompaña este informe. En este documento se presentan únicamente la metodología, los resultados principales y su interpretación.

1. Carga y exploración de datos

El conjunto de datos contiene **100.000 registros** y dos variables numéricas continuas:

Variable	Descripción	Unidad
<code>tamano</code>	Tamaño de la vivienda	m^2
<code>precio</code>	Precio de la vivienda	COP

Las estadísticas descriptivas iniciales se resumen en la Tabla 1.

Tabla 1: Estadísticas descriptivas de las variables originales.

Variable	Observaciones	Media	Mediana	Desv. estándar	Mínimo	Q1	Q3	Máximo
<code>tamano</code>	90.000	150,07	150,10	44,91	30,00	119,60	180,40	351,60
<code>precio</code>	95.000	425.238,13	425.243,50	123.138,41	30.000,00	342.106,75	508.401,25	1.002.767,00

La similitud entre media y mediana sugiere que las distribuciones no presentan una asimetría extrema. Además, desde la exploración inicial se observa una relación positiva fuerte entre el tamaño y el precio de las viviendas.

2. Tratamiento de datos faltantes

La variable `tamano` presenta **10.000 valores faltantes (10 %)** y `precio` presenta **5.000 valores faltantes (5 %)**.

Tabla 2: Resumen de valores faltantes.

Variable	Valores faltantes	Valores observados	Porcentaje faltante
<code>tamano</code>	10.000	90.000	10,0 %
<code>precio</code>	5.000	95.000	5,0 %

El análisis conjunto mostró que el **85,5 %** de los registros estaba completamente observado; el **9,5 %** tenía únicamente `tamano` faltante, el **4,5 %** únicamente `precio` faltante y el **0,5 %** presentaba ambas variables faltantes.

Selección del método de imputación

Se compararon métodos simples y multivariados de imputación. Para seleccionar la estrategia se utilizó el **NRMSE promedio**, donde un valor menor indica una mejor capacidad de reconstrucción de datos conocidos que fueron ocultos temporalmente durante la validación.

Tabla 3: Comparación de los métodos de imputación.

Posición	Método	NRMSE promedio
1	IterativeImputer + BayesianRidge	0,3926
2	KNN (k = 5)	0,4751
3	Mediana	0,9997
4	Media	0,9997

Se seleccionó **IterativeImputer con BayesianRidge** porque obtuvo el menor error de reconstrucción y, a diferencia de la media o la mediana, aprovecha la relación existente entre **tamano** y **precio**.

Después de la imputación, ambas variables quedaron con **0 valores faltantes**. Las estadísticas antes y después permanecieron muy similares y la correlación entre **tamano** y **precio** pasó de **0,9143** a **0,9252**. Este cambio es pequeño y muestra que la fuerte relación lineal positiva se conservó sin una alteración sustancial de la estructura de los datos.

3. Construcción del modelo de regresión lineal

Se utilizó el **dataset completo después de la imputación**. La variable predictora fue **tamano** y la variable objetivo fue **precio**.

El conjunto de datos se dividió de la siguiente manera:

Tabla 4: División del conjunto de datos.

Conjunto	Registros	Porcentaje
Entrenamiento	80.000	80 %
Prueba	20.000	20 %

El modelo estimado fue:

$$\widehat{Precio} = 43.002,89 + 2.547,77 \times tamaño$$

El coeficiente indica que, en promedio, por cada **1 m² adicional**, el precio estimado aumenta aproximadamente en **\$2.547,77 COP**.

El **intercepto de \$43.002,89 COP** representa el precio estimado cuando el tamaño es **0 m²**; sin embargo, su interpretación práctica es limitada, ya que una vivienda de **0 m²** no tiene sentido real.

4. Evaluación del modelo

El desempeño se evaluó sobre los **20.000 registros del conjunto de prueba**.

Tabla 5: Métricas de evaluación del modelo.

Métrica	Resultado
R^2	0,8539
RMSE	\$46.668,86 COP
MAPE	9,65 %

El modelo explica aproximadamente el **85,39 % de la variabilidad del precio** a partir del tamaño de la vivienda. El RMSE fue de **\$46.668,86 COP** y el MAPE de **9,65 %**, lo que indica que las predicciones presentan, en promedio, un error porcentual cercano al 9,65 % respecto al precio real.

En conjunto, los resultados muestran un **buen desempeño predictivo** para un modelo lineal simple con una única variable explicativa.

5. Predicción

La implementación interactiva se encuentra en el notebook de Colab. Para efectos del informe se presenta una prueba con una vivienda de **150 m^2** :

Vivienda de 150 m^2 $\rightarrow$ Precio estimado: \$425.168,27 COP

La predicción corresponde al valor esperado por el modelo según la relación aprendida entre tamaño y precio. No representa necesariamente el precio exacto de una observación individual, ya que existe variabilidad alrededor de la tendencia lineal.

6. Visualización de resultados

Datos y línea de regresión




Figura 1: Relación entre tamaño y precio con la línea de regresión estimada.

La Figura 1 evidencia una **relación lineal positiva**: a medida que aumenta el tamaño de la vivienda, también aumenta su precio esperado. La línea representa la tendencia estimada por el modelo sobre el conjunto de datos imputado.

Análisis de residuos




Figura 2: Residuos del modelo en función del precio estimado.

Los residuos se distribuyen principalmente alrededor de **cero**, sin evidenciar una curvatura marcada. Aunque existen algunos errores extremos y cierta dispersión, el comportamiento general es consistente con el buen desempeño predictivo obtenido por el modelo.

Conclusiones

El tratamiento de los datos faltantes mediante **IterativeImputer** + **BayesianRidge** permitió obtener un conjunto completo conservando adecuadamente la estructura de los datos. La estrategia fue seleccionada mediante una comparación empírica y presentó el menor NRMSE promedio entre los métodos evaluados.

Posteriormente, el modelo de regresión lineal obtuvo un R^2 de **0,8539** y un MAPE de **9,65 %**, evidenciando que el tamaño explica una proporción importante de la variabilidad del precio y que el modelo ofrece una capacidad predictiva adecuada para el objetivo planteado.

El notebook de Colab conserva el **desarrollo técnico completo y reproducible**, mientras que este informe resume los elementos metodológicos, resultados e interpretaciones necesarios para la entrega académica.