

Informe: Regresión con Árboles de Decisión (California Housing)

Universidad El Bosque - Aprendizaje Supervisado Avanzado

Juan Sebastian Laverde Chunza

1. Objetivo y datos

El objetivo fue entrenar, interpretar y comparar **Árboles de Decisión para regresión** sobre el conjunto *California Housing*, utilizando `MedHouseVal` como variable objetivo. El análisis empleó ocho variables predictoras numéricas: `MedInc`, `HouseAge`, `AveRooms`, `AveBedrms`, `Population`, `AveOccup`, `Latitude` y `Longitude`.

Después de la preparación realizada en el notebook se trabajó con **20.433 observaciones**. La partición fue de **70 % para entrenamiento y 30 % para prueba**, con `random_state=0`.

2. Análisis exploratorio de datos

El análisis exploratorio se centró para este informe en dos aspectos; la relación entre las variables predictoras y `MedHouseVal`, y la comprobación visual de datos faltantes en el conjunto finalmente utilizado por el modelo.

2.1. Relación entre las predictoras y la variable objetivo

La Figura 1 muestra la relación entre cada una de las ocho variables predictoras y `MedHouseVal`. `MedInc` presenta la asociación visual más clara con el valor de la vivienda. `Latitude` y `Longitude` exhiben patrones geográficos que sugieren relaciones más complejas que una tendencia lineal simple, mientras que variables como `AveRooms`, `AveBedrms`, `Population` y `AveOccup` presentan mayor dispersión y algunos valores extremos.




Figura 1: Relación entre las ocho variables predictoras y MedHouseVal.

La matriz de correlación calculada en el notebook muestra además que MedInc alcanza una correlación aproximada de **0,688** con MedHouseVal, superior a la de las demás variables. Esta medida es útil para el EDA, aunque el Árbol de Decisión también puede capturar relaciones no lineales e interacciones entre variables.

2.2. Comprobación de datos faltantes

La Figura 2 permite comprobar visualmente la presencia o ausencia de valores faltantes. Después de la preparación utilizada en el notebook, las nueve variables analizadas presentan **0 valores faltantes**, por lo que el conjunto empleado para el entrenamiento no requiere imputación adicional.




Figura 2: Mapa visual de datos faltantes del conjunto utilizado.

3. Árbol de Decisión con las ocho variables

El primer modelo se entrenó con las **ocho variables predictoras** y sin limitar explícitamente su profundidad. El árbol alcanzó una profundidad de **34 niveles** y **13.662 hojas**, lo que evidencia una estructura altamente flexible y con capacidad para ajustarse con gran detalle a los datos de entrenamiento.

La Figura 3 muestra únicamente los primeros niveles del árbol para facilitar su lectura. El parámetro `max_depth=3` utilizado en `plot_tree()` limita solamente la **visualización**; no modifica la profundidad real del modelo entrenado.

Árbol de Regresión: California Housing → MedHouseVal




Figura 3: Primeros niveles del Árbol de Decisión entrenado con las ocho variables predictoras.

3.1. Importancia de las variables dentro del árbol

El análisis de `feature_importances_` permite identificar cuáles variables tuvieron una mayor participación en las divisiones del árbol.

Variable	Importancia	Participación aproximada
MedInc	0,5082	50,82 %
AveOccup	0,1379	13,79 %
Latitude	0,1002	10,02 %
Longitude	0,0985	9,85 %
HouseAge	0,0578	5,78 %
AveRooms	0,0362	3,62 %
Population	0,0314	3,14 %
AveBedrms	0,0299	2,99 %




Figura 4: Importancia de las variables en el Árbol de Decisión de ocho variables.

Las cuatro variables principales - `MedInc`, `AveOccup`, `Latitude` y `Longitude` - concentran aproximadamente **84,5 %** de la importancia total. `MedInc` domina el modelo con cerca del **50,8 %**. La importancia mide la contribución de cada variable a las divisiones del árbol, pero no indica por sí sola si el efecto sobre `MedHouseVal` es positivo o negativo.

4. Modelo reducido con cuatro variables

A partir del análisis de importancia se construyó un segundo árbol utilizando `MedInc`, `AveOccup`, `Latitude` y `Longitude`. En este modelo se controló la complejidad mediante `max_depth=11` y `min_samples_leaf=10`.

La Figura 5 presenta los primeros niveles del árbol reducido. Las divisiones iniciales vuelven a destacar principalmente `MedInc`, acompañada por `AveOccup` y las variables geográficas.

Árbol de Regresión con las 4 variables más importantes




Figura 5: Primeros niveles del Árbol de Decisión construido con las cuatro variables de mayor importancia.

5. Comparación del error de predicción

La comparación se realizó sobre los conjuntos de prueba mediante el **Error Cuadrático Medio (MSE)** y la **Raíz del Error Cuadrático Medio (RMSE)**. Un valor menor indica predicciones más próximas a los valores observados.

Modelo	Variables	Configuración	MSE de prueba	RMSE de prueba
Árbol completo	8	Sin límite explícito de profundidad	5.615.215.727,16	74.935
Árbol reducido	4	<code>max_depth=11,</code> <code>min_samples_leaf=10</code>	3.304.114.660,47	57.481




Figura 6: Comparación del RMSE de los dos modelos.

En esta evaluación, el modelo reducido obtuvo un RMSE aproximadamente **23,3 % menor** que el árbol completo. El resultado sugiere una mejor generalización del segundo modelo sobre el conjunto de prueba.

Nota metodológica. Los dos modelos no difieren únicamente en el número de variables. El árbol de ocho variables fue entrenado sin limitar su profundidad, mientras que el árbol de cuatro variables incorpora control de complejidad mediante `max_depth` y `min_samples_leaf`. Por esta razón, la reducción del error no puede atribuirse exclusivamente a la selección de variables.

6. Conclusiones

El EDA mostró que **MedInc** presenta la relación más evidente con **MedHouseVal** y confirmó visualmente que no existe ausencia de datos faltantes en el conjunto de datos. El Árbol de Decisión con ocho variables alcanzó una profundidad elevada, mientras que el análisis de importancia mostró que **MedInc**, **AveOccup**, **Latitude** y **Longitude** concentran cerca del **84,5 %** de la importancia total.

El modelo reducido y regularizado obtuvo un menor error de prueba (**RMSE 57.481 frente a 74.935**). En este ejercicio, reducir el conjunto de variables y controlar la complejidad produjo un modelo más parsimonioso y con mejor desempeño de prueba, aunque una comparación estricta del efecto de la selección de variables requeriría entrenar ambos árboles con los mismos hiperparámetros.